

Documentație Tehnică

NLP Dataset Generation in /medical Domain in English

Studenti: Tulbure Robert, Popa Denis-Ionut

Coordonator: Drd. Szomiu Roxana

1.Motivatie:

Am ales acest proiect din dorinta de a dezvolta un dataset propriu in domeniul medical folosindu-ne de site-urile existente care redau glosare medicale sau telemedicina in limba engleza.

2.Obiective:

Ne propunem sa construim un sistem inteligent constand in 3 agenti care conlustrand sa prelucreze datele primite de la un scraper, sa le extraga, sa le valideze si sa le testeze.

In urma acestor proceduri, va rezulta un dataset propriu pe care il vom folosi pentru a compara diferite modele de LLM-uri locale (llama3.2:3b si mistral).

De asemenea, dorim sa antrenam 2 modele : SVM si Logisitic Regression.

In final, vom compara rezultatele si performantele acestor modele.

3. Arhitectura :

-agent: Definirea celor 3 agenti . Cine face taskurile?

Agent1: extrage datele medicale

Agent2: Verifica validitatea randurilor din dataset
(daca sunt curate, coerente)

Agent3: Tester/ face un raport calitativ

-tasks: Taskurile impotant.Ce trebuie facut.?

-crew: Cum sunt legati agentii impreuna?

Proces secvential : Extractor, Validator, Tester.

-tools: Logica

-dataset_pipeline: Orchestrarea end2end

4. Descrierea proiectului:

Proiectul are 2 faze: Creerea unui dataset propriu folosind trei agenti in cadrul arhitecturii descrise mai sus si Antrenarea unor modele/algoritmi invatati in cadrul laboratorului de Sisteme Inteligente si anume Support Vector Machine si Logistic Regression.

Ambele faze contin parti in care am realizat analiza de performata a toolurilor folosite.

5. Lansarea si folosirea aplicatiei:

5.1. Se porneste ollama; ex: ollama pull mistral

5.2. Se porneste mediul python in folderul proiectului: `.venv\Scripts\activate`

5.3. Se ruleaza proiectul cu comanda in terminal:
`python -m src.nlp_medical_dataset.main`

5.4 Rezultatele se pot consulta in data/final, iar rapoartele de calitate si metricile, in reports.

5.5. Moelele se antreneaza din notebookurile aferente acestora.

5.6. Obs: Site-urile din care se extrag datele pot fi schimbate in sources.csv de catre utilizator, acesta putand adauga site-uri la alegere, dar care respecta formatul simptoma-boala-tratament/recomandare, etc.